

LISTA # 2 - ESCOLHA DINÂMICA DISCRETA

Nessa lista vamos estimar um modelo dinâmico de escolha discreta e usar nossos resultados para fazer simulações contrafactuais. O modelo é inspirado no modelo clássico de reposição de máquinas apresentado em Rust (1987). Todas as dicas se referem a implementação em Matlab, mas serão úteis também em outras implementações. Fiquem a vontade para usar R ou Python se preferirem. Além da solução por escrito, vocês devem também entregar os códigos.

Temos uma firma que atua em  $N$  mercados distintos de operação independente, indexados  $n = 1, \dots, N$ . Para produzir seu produto em cada mercado a firma utiliza uma máquina que se deprecia rapidamente e precisa ser reposta, paralisando as operações da firma no mercado. No início de cada período a firma precisa decidir se troca a máquina. Caso a firma decida não trocar a máquina no início do período  $t$ , o lucro da firma é dado por

$$\theta x_n(1 - \alpha a_{nt}) + \varepsilon_{0nt},$$

em que  $x_n$  é uma medida do tamanho do mercado  $n$ ,  $a_{nt}$  é a idade da máquina da firma no mercado  $n$  no período  $t$  e  $\varepsilon_{0nt}$  é um choque.

Caso a firma decida trocar a máquina no período  $t$  seu lucro é somente  $-\phi + \varepsilon_{1nt}$ , em que  $\phi$  é o custo de reposição da máquina e  $\varepsilon_{1nt}$  é também um choque. Suponha que  $\varepsilon_{0nt}$  e  $\varepsilon_{1nt}$  são iid e com distribuição valor extremo do tipo 1.

Quando a firma troca sua máquina em  $t$ , a idade da sua máquina no período seguinte é 0, ou seja,  $a_{n,t+1} = 0$ . Caso não haja troca, a máquina envelhece no período seguinte até um limite máximo de 10, mais precisamente,  $a_{n,t+1} = \min\{a_{n,t} + 1, 10\}$ . Firms maximizam em suas decisões o valor presente esperado do fluxo de lucros descontado  $\mathbb{E} \sum_{t=0}^{\infty} \rho^t \pi_{nt}$ . Nesse exercício, assumimos que conhecemos a taxa de desconto verdadeira:  $\rho = 0.9$ .

Vocês tem acesso a uma base de dados em que cada linha representa um mercado  $n$  em um período  $t$ , com as seguintes variáveis:

- Market: indicador de mercado ( $n$ );
- MarketSize: tamanho do mercado ( $x_n$ );
- t: indicador de período ( $t$ );
- age: idade da máquina ( $a_{nt}$ ).

**Parte I: Setup**

1. Equações de Bellman.

- (a) Escreva as equações de Bellman que representam o problema dinâmico da firma na sua versão completa como função de todas as variáveis de estado, ou seja,  $V(x_n, a_{nt}, \varepsilon_{0nt}, \varepsilon_{1nt})$ .

- (b) Escreva as equações de Bellman no formato integrado, ou seja, apenas como função das variáveis de estado  $x_n$  e  $a_{nt}$ :  $V(x_n, a_{nt})$ .
  - (c) Escreva a fórmula para as *Conditional Choice Probabilities* (CCPs) de se escolher trocar a máquina no período  $t$  no mercado  $n$  como função das variáveis de estado e da função valor encontrada no item anterior.
2. Crie uma nova variável,  $c_{nt}$ , que represente a escolha feita no período  $t$ . Ou seja,  $c_{nt} = 1$ , caso a troca tenha sido feita no período  $t$  e  $c_{nt} = 0$ , caso contrário.  
*Dica: Notem que não será possível criar a variável  $c_{nt}$  para todos os períodos. Observações em que não é possível conhecer  $c_{nt}$  não serão usadas em nossa análise.*
3. Estime um modelo de probabilidade linear para a decisão de troca da máquina:

$$c_{nt} = \beta_0 + \beta_1 x_n + \beta_2 a_{nt} + v_{nt}.$$

Reporte o vetor estimado  $\hat{\beta}$  e seus erros-padrão. Interprete o resultado. Os sinais das estimativas fazem sentido econômico?

## Parte II: Estimação

Nessa parte vamos estimar o vetor de parâmetros estruturais do modelo  $(\theta, \alpha, \phi)$  por *Maximum Likelihood* (ML) utilizando o algoritmo de *Nested Fixed Point* (NFXP). A ideia é que para cada avaliação da função objetivo de ML ao longo da otimização, precisaremos encontrar as funções valores por iteração, construir as CCPs e avaliar a verossimilhança na amostra.

1. Crie uma função que compute a *log-likelihood* tendo como entradas os dados e o vetor de parâmetros desconhecidos. Por exemplo,  $\text{LogLikelihood}(\text{Par}, \text{Data})$ .
  - (a) Para o vetor de parâmetros dados na entrada, precisaremos primeiro computar a função valor  $V(x, a)$  por iteração e depois  $\text{CCP}(x, a)$  utilizando a expressão encontrada na Parte I.  
*Dicas: Comecem criando um grid para todos os valores possíveis de  $x$  (note que nos dados  $x$  assume um número relativamente pequeno de valores) e outro para  $a$ . Como temos duas variáveis de estado, é mais fácil fazer a iteração utilizando uma orientação matricial para  $V$ , e consequentemente  $\text{CCP}$ , mas não é necessário. Escrevam um *while loop* que computa a função valor para todos os pontos dos grids utilizando o método da contração. Fiquem atentos ao problema quando  $a = 10$ . Após a convergência da contração, compute as CCPs.*
  - (b) O próximo passo é usar as CCPs encontradas para computar a *likelihood* das observações.  
*Dicas: Aqui vocês precisam encontrar para cada observação a entrada correspondente na matriz (ou vetor) CCP. A maneira mais fácil e rápida é criando uma nova variável, vamos chamá-la de ‘state’, na base de dados (isso deve ser feito fora da função  $\text{LogLikelihood}$ ) que informa o índice daquela observação na matriz (ou vetor)  $V$  e  $\text{CCP}$ . Por exemplo, se uma observação tem  $x = 1$  e  $a = 7$ , temos que*

*procurar qual a entrada na matriz CCP correspondente. Suponha que a entrada correspondente a  $x = 1$  e  $a = 7$  em CCP seja a 107. Então a variável ‘state’ para essa observação deve informar o número 107. Com essa variável definida, se chamamos  $CCP(state)$  obtemos o vetor de CCPs para cada observação na nossa amostra.*

2. Utilize uma função pronta (por exemplo, *fminunc* no Matlab) com otimização baseada em gradiente para encontrar o vetor de parâmetros que maximiza a função objetivo  $LogLikelihood(Par, Data)$ .

*Dica: Você precisará informar um vetor inicial para busca. Utilize  $(\theta, \alpha, \phi) = (1, 0.1, 1)$ . Qualquer vetor numa região razoável deve funcionar.*

### **Parte III: Contrafactual**

Apenas como um exemplo, vamos avaliar como as políticas da firma mudam depois de uma alteração do custo de reposição.

1. Utilizando os parâmetros estimados, compute as CCPs. Esse será o cenário ‘baseline’.
2. Agora, reduza o custo de reposição em 50%. Recompute as CCPs.
3. Fixe  $x = 1$  e reporte o vetor de CCPs para os dois cenários. Isto é, em cada cenário haverá uma CCP para cada idade possível da máquina. Compare os dois cenários.